TRƯỜNG ĐẠI HỌC SÀI GÒN · KHOA CÔNG NGHỆ THÔNG TIN · MÔN HỌC MÁY

CHALLENGE 1: HOUSE PRICES PREDICTION

Feature Selection, Feature Engineering và Ensemble Blending trên tập dữ liệu Ames Housing

Nhóm 5 – Lớp DCT124C1

Phạm Minh Khôi (3124411135) · Trương Thuận Phú (3124411234) · Nguyễn Mạnh Thắng (3124411283) · Nguyễn Hoàng Quân (3124411250)

Giảng viên hướng dẫn: TS. Đỗ Như Tài

Tháng 11/2026

Nội dung trình bày

1. **Giới thiệu bài toán**
   Input/Output, dữ liệu, thách thức
2. **Khám phá dữ liệu (EDA)**
   Phân phối giá, ngoại lai, tương quan
3. **Phương pháp**
   Tiền xử lý, chọn đặc trưng, 5 mô hình, FE + blending
4. **Thực nghiệm**
   CV không rò rỉ, ablation, mô hình cuối, Kaggle
5. **Kết luận**
   Đóng góp, hạn chế, hướng phát triển

1. Phát biểu bài toán: dự đoán giá bán nhà

INPUT

79 đặc trưng của một căn nhà (diện tích, chất lượng, vị trí, năm xây, gara, tầng hầm…)

MÔ HÌNH

Hồi quy học máy
Ridge · SVR · RF · GBDT
+ blending

OUTPUT

SalePrice (USD)
huấn luyện trên log1p(SalePrice)

Mục tiêu

- Hiểu dữ liệu và làm sạch có cơ sở
- Đo tác động của chọn đặc trưng, log, ngoại lai
- Xây mô hình nộp Kaggle có CV đáng tin

Thước đo

- RMSE trên log1p(SalePrice) (thấp hơn là tốt hơn)
- R^2 trên thang log
- 5-fold CV, Pipeline (không rò rỉ dữ liệu)

Nguồn: Kaggle "House Prices: Advanced Regression Techniques"; dữ liệu Ames Housing (De Cock, 2011).

2. Dữ liệu Ames Housing và các thách thức

Thuộc tính	Giá trị
Mẫu huấn luyện	1.460 → 1.458 (loại 2 ngoại lai)
Mẫu kiểm thử	1.459
Biến dự báo	79 (36 số, 43 định tính)
Giai đoạn	2006–2010, Ames, Iowa

Lưu ý: NA trong PoolQC, Alley, Fence… không phải mất dữ liệu; nhóm điền "None" thay vì suy diễn.

Thách thức

- Số chiều lớn: 79 biến trên chỉ 1.458 mẫu
- Dữ liệu hỗn hợp số + định danh/thứ bậc
- Khuyết nhiều: PoolQC 99,5%, MiscFeature 96,3%, Alley 93,8%, Fence 80,8%
- Khuyết thường mang nghĩa "không có" (không hồ bơi, không gara)
- Đa cộng tuyến mạnh (GarageCars–GarageArea r = 0,89)
- Giá lệch phải, có ngoại lai

Nguồn: tài liệu mô tả dữ liệu Kaggle (data_description.txt).

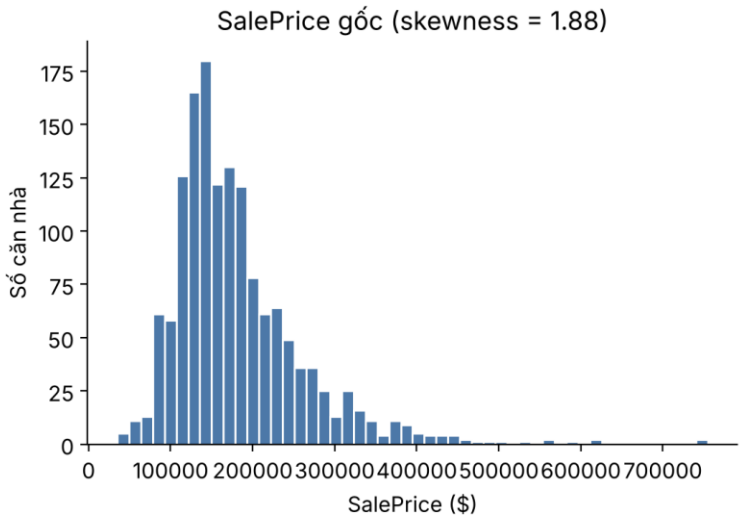
3. Quy trình thực nghiệm đầu–cuối

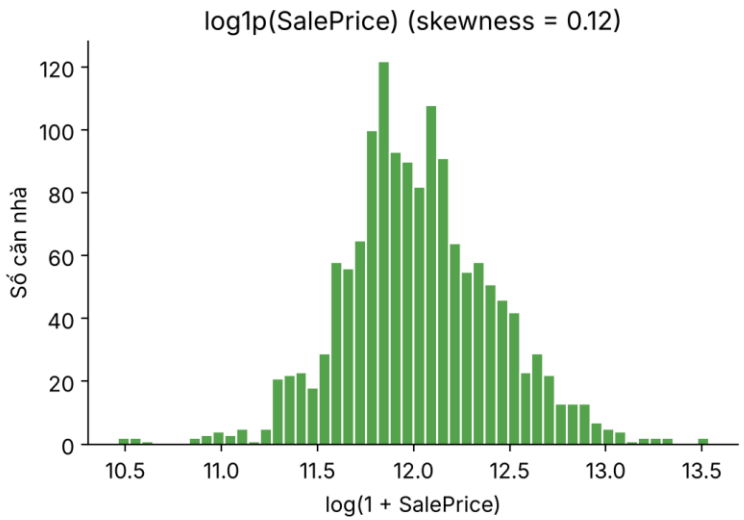


Điểm nhấn của quy trình

- Chuẩn hóa và chọn đặc trưng nằm trong Pipeline → mỗi fold chỉ học từ dữ liệu huấn luyện của fold
- Ablation định lượng cho log-transform và loại ngoại lai
- Mô hình nộp cuối được đánh giá bằng CV riêng; hình Actual vs Predicted dùng dự đoán out-of-fold

EDA: phân phối biến mục tiêu và log-transform



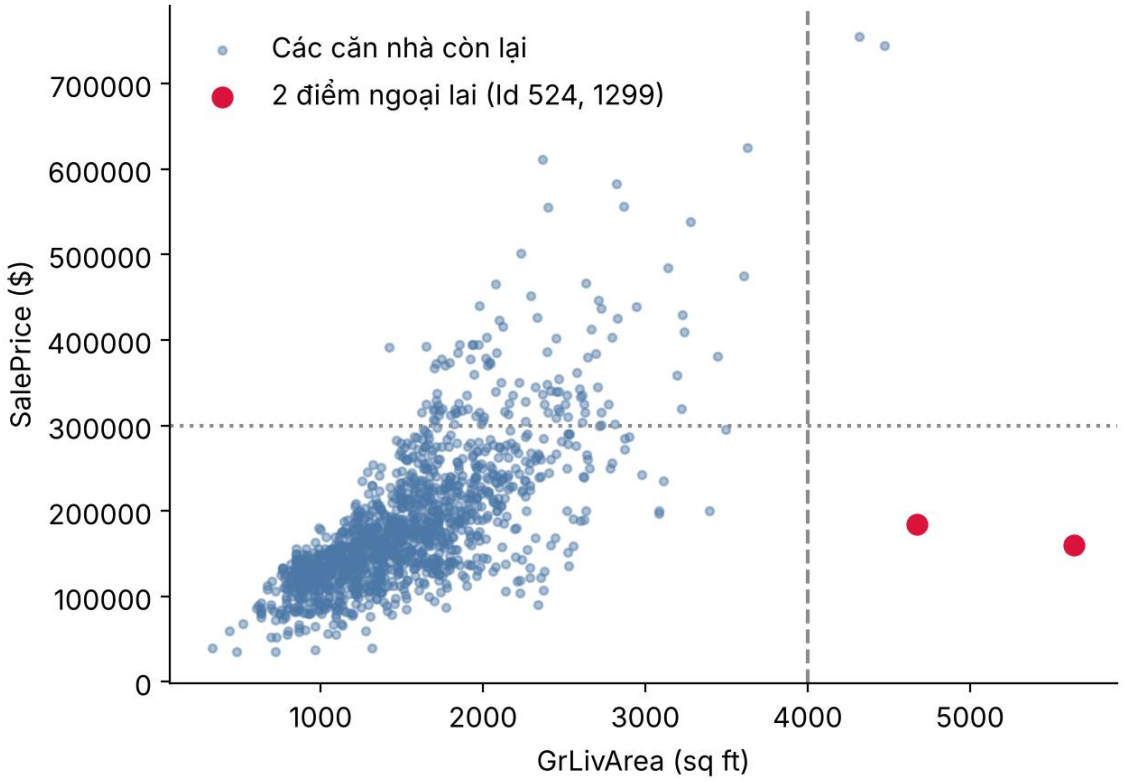


Nhận xét

- Skewness gốc **1,88**, đuôi dài đến 755.000$
- Sau log1p: **0,12**, gần đối xứng
- Khớp thước đo cuộc thi (RMSE trên log)
- Log đặc biệt quan trọng với Ridge (xem ablation)

Kết luận: dùng log1p(SalePrice) làm biến mục tiêu cho toàn bộ mô hình.

EDA: hai điểm ngoại lai theo khuyến nghị của De Cock



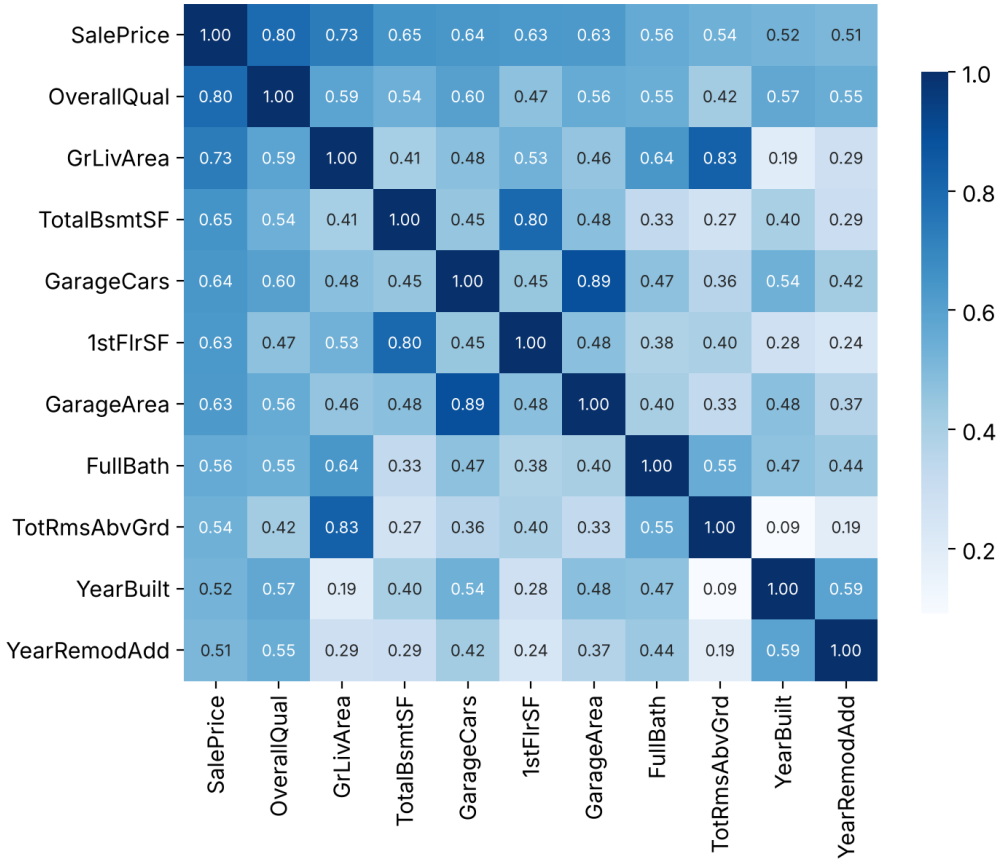
Phát hiện

- Id **524** và **1299**: GrLivArea > 4.000 sq ft nhưng giá 184.750$ và 160.000$
- Cả hai có SaleCondition = **Partial** (nhà chưa hoàn thiện khi định giá)
- Không phản ánh thị trường bình thường → loại bỏ
- Còn 1.458 mẫu

Tác động: Ridge RMSE 0,1388 → 0,1221 khi loại (−12%); mô hình cây gần như không đổi.

Nguồn: De Cock (2011), Journal of Statistics Education 19(3).

EDA: tương quan Pearson và đa cộng tuyến



Phát hiện chính

- OverallQual r = **0,80**, GrLivArea **0,73**
- TotalBsmtSF 0,65, GarageCars 0,64, 1stFlrSF 0,63
- Đa cộng tuyến mạnh:
- GarageCars–GarageArea 0,89
- TotalBsmtSF–1stFlrSF 0,80
- YearBuilt–GarageYrBlt 0,83
- → cần điều chuẩn (Ridge/Lasso) và xem xét chọn đặc trưng

4. Tiền xử lý dữ liệu

Điền khuyết

- Định tính: NA → "None"
- Tiện ích không tồn tại (diện tích hầm, gara, MasVnrArea…): → 0
- LotFrontage: median theo Neighborhood
- Cột số còn lại: median của train

Mã hóa, chuẩn hóa, mục tiêu

- Mã hóa nhãn cho 43 biến định tính
- StandardScaler **trong Pipeline** (fit theo fold)
- Mục tiêu: $\ell = \log(1 + y)$; dự đoán: $\hat{y} = \exp(\hat{\ell}) - 1$
- Loại 2 ngoại lai (Id 524, 1299)

5. Ba chiến lược chọn đặc trưng

Full (baseline)

- Giữ cả **79** biến
- Mốc đối chứng

Filter: SelectKBest

- F-regression, **k = 30**
- Tương quan tuyến tính đơn biến với log giá
- Nhanh, không xét tương tác

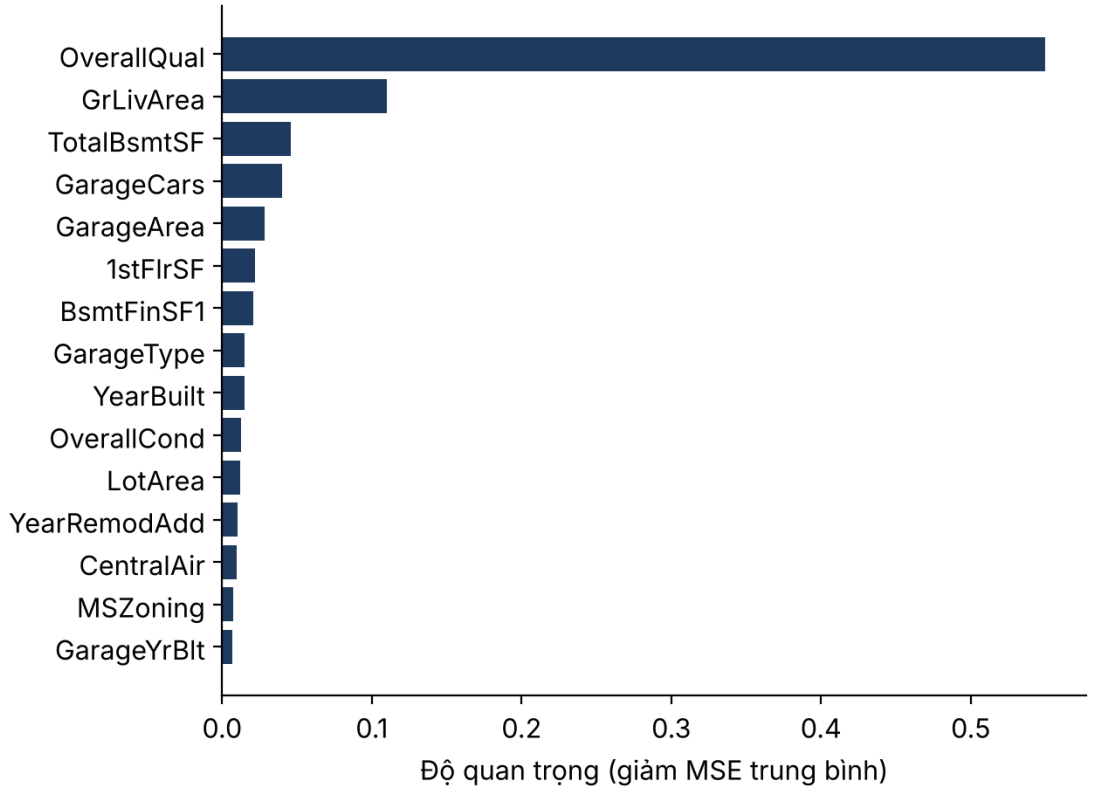
Embedded: RF top-25

- Random Forest 100 cây
- Độ quan trọng = giảm MSE (không phải Gini)
- Giữ **25** biến, chiếm 94,8% tổng độ quan trọng

Cả hai bộ chọn đặt trong **Pipeline** sau StandardScaler → không rò rỉ dữ liệu giữa các fold.
Giảm 79 → 25 biến = **giảm 68,4%** số chiều.

Guyon & Elisseeff (2003), JMLR 3: filter / wrapper / embedded.

Độ quan trọng đặc trưng từ Random Forest



Nhận xét

- **OverallQual** chiếm ~55% tổng độ quan trọng
- GrLivArea (~11%), TotalBsmtSF, GarageCars, GarageArea, 1stFlrSF
- Nhóm biến diện tích + chất lượng chi phối giá
- Hình minh họa: RF huấn luyện trên toàn bộ dữ liệu (trong CV, chọn biến chạy riêng từng fold)

6. Năm mô hình hồi quy

Ridge	Tuyến tính + L2, $\alpha = 10$
SVR	Nhân RBF, $C = 1$, $\varepsilon = 0{,}1$
Random Forest	Bagging, 100 cây
Gradient Boosting	100 cây, lr = 0,08
XGBoost	100 vòng, lr = 0,08, depth ≤ 4

Siêu tham số cố định ở thực nghiệm chính (chưa tinh chỉnh); tinh chỉnh ở bước cuối.

Pedregosa et al. (2011), scikit-learn; XGBoost = histogram gradient boosting (cùng họ XGBoost/LightGBM).

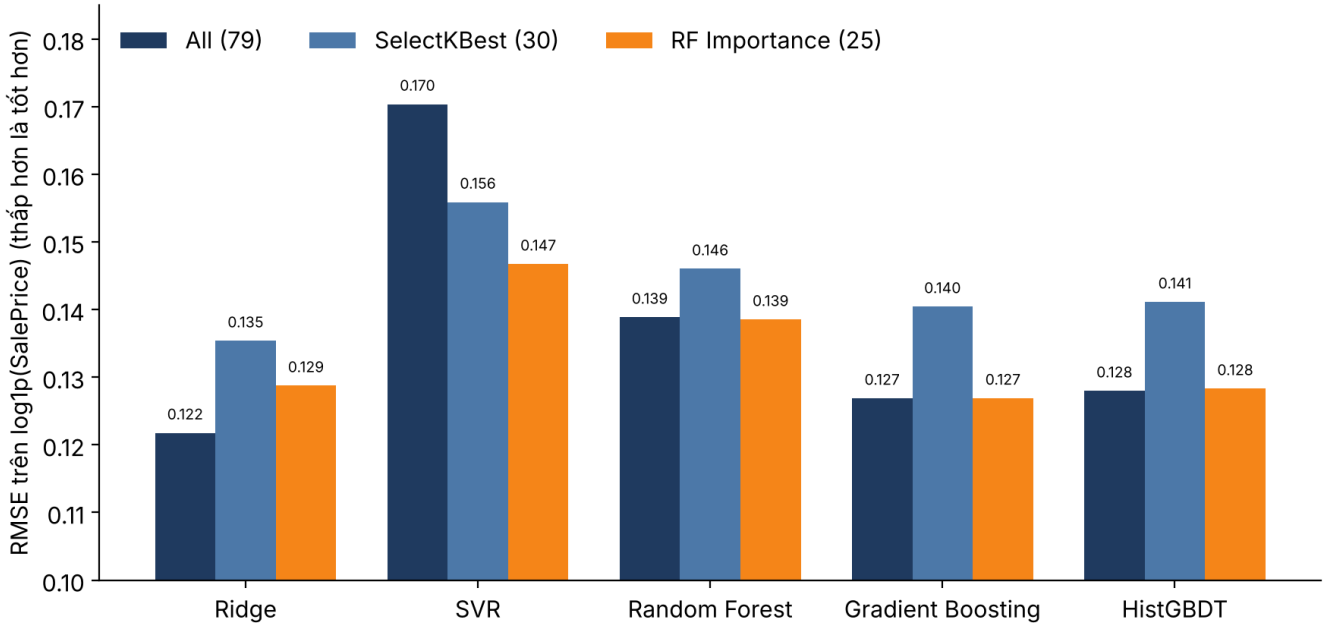
7. Kết quả chính: 3 tập đặc trưng × 5 mô hình (5-fold CV)

Mô hình	All (79)	SelectKBest (30)	RF top-25
Ridge	0,1218	0,1354	0,1287
SVR	0,1703	0,1559	0,1467
Random Forest	0,1390	0,1461	0,1385
Gradient Boosting	0,1269	0,1404	0,1269
XGBoost	0,1255	0,1401	0,1255

Ridge trên 79 biến tốt nhất (0,1218; R^2 0,9065), ngang Gradient Boosting (0,1269): chênh lệch < độ lệch chuẩn giữa các fold (~0,009).

Độ lệch chuẩn RMSE giữa các fold ≈ 0,007–0,019.

Chọn đặc trưng giúp hay hại?



Kết luận từ số liệu

- **Ridge:** RF top-25 làm xấu đi (0,1218 → 0,1287)
- **SelectKBest** hại hầu hết mô hình (chỉ xét tương quan tuyến tính)
- **GBDT:** top-25 ≈ toàn bộ biến, bỏ 68% biến mà không mất
- **SVR:** 0,1703 → 0,1467 (**−13,9%**)
- Không đo được tăng tốc: chọn biến chạy trong từng fold

8. Ablation: log-transform và loại ngoại lai

Ngoại lai	Biến mục tiêu	Ridge	Gradient Boosting
Đã loại	log1p(y)	0,1221	0,1272
Đã loại	y (không log)	0,1574	0,1298
Giữ lại	log1p(y)	0,1388	0,1272
Giữ lại	y (không log)	0,3520	0,1312

- **Log-transform:** Ridge 0,157 → 0,122 (−22%); Gradient Boosting gần như không đổi.
- **Loại ngoại lai:** Ridge 0,139 → 0,122 (−12%); không log + giữ ngoại lai → Ridge hỏng (0,35).
- Hai bước này then chốt với mô hình **tuyến tính**; mô hình cây bền vững hơn.

RMSE luôn tính trên cùng 1.458 căn nhà để so sánh công bằng.

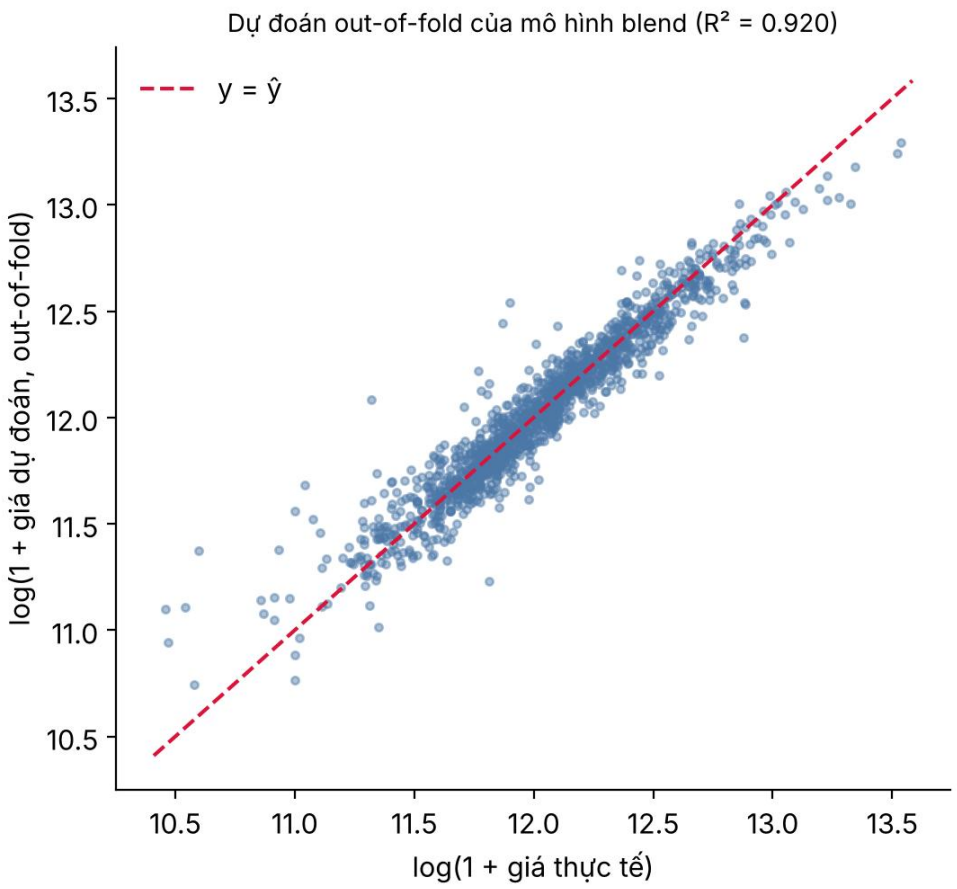
9. Feature engineering + tinh chỉnh + blending

Cấu hình	RMSE	R^2
Ridge (α=10), 79 biến gốc	0,1218	0,9065
Ridge tinh chỉnh + FE + log biến lệch	0,1197	0,9095
Lasso tinh chỉnh + FE + log biến lệch	0,1188	0,9106
GBDT tinh chỉnh + FE + log biến lệch	0,1161	0,9152
Blend: 0.25 Ridge + 0.25 Lasso + 0.5 GBDT	**0,1127**	**0,9202**

- +8 đặc trưng mới (TotalSF, TotalBath, HouseAge, QualxArea…) → 87 biến; log1p 21 biến lệch
- Ridge α = 100, Lasso α = 0,002; GBDT 600 cây, lr 0,03
- **Blend đạt RMSE 0,1127 (R^2 0,9202)**, giảm 7,5% so với baseline Ridge

Lưu ý: α chọn trên cùng 5 fold (không nested CV) nên số liệu bước này có thể hơi lạc quan.

Dự đoán out-of-fold của mô hình blend



Đọc biểu đồ

- Mỗi điểm là một căn nhà được dự đoán bởi mô hình **chưa thấy** nó khi huấn luyện
- R^2 = **0,9202**, khớp bảng kết quả
- Sai số lớn tập trung ở nhà giá thấp (dữ liệu thưa)

10. Kết quả nộp bài trên Kaggle



File nộp: submission.csv (mô hình blend) | Public score (RMSE log): 0,12455 | Thời điểm: 09/11/2026

Public score 0,12455 cao hơn RMSE CV của blend (0,1127) khoảng 0,012: α Ridge/Lasso chọn trên chính 5 fold báo cáo (CV hơi lạc quan) và tập kiểm thử là dữ liệu mới; chưa kiểm chứng bằng nested CV.

11. Kết luận và hướng phát triển

Kết luận

- Trên 79 biến, Ridge ≈ Gradient Boosting (0,1218 vs 0,1269)
- Chọn đặc trưng: không giúp Ridge/cây, giúp SVR (−13,9%), giảm 68% biến cho GBDT mà không mất
- Log và loại ngoại lai: then chốt cho mô hình tuyến tính
- Blend cuối: RMSE **0,1127**, R^2 **0,9202**

Hạn chế và hướng tiếp theo

- Chưa dùng nested CV cho bước tinh chỉnh
- Siêu tham số SVR/RF/GBDT ở thực nghiệm chính chưa tối ưu
- Thử one-hot / target encoding cho biến danh nghĩa
- Stacking, XGBoost/LightGBM, Optuna

Tài liệu tham khảo

[1] De Cock, D. (2011). Ames, Iowa: Alternative to the Boston Housing Data… J. Statistics Education 19(3).

[2] Hoerl & Kennard (1970). Ridge Regression. Technometrics 12(1).

[3] Tibshirani (1996). Regression Shrinkage and Selection via the Lasso. JRSS-B 58(1).

[4] Breiman (2001). Random Forests. Machine Learning 45(1).

[5] Friedman (2001). Greedy Function Approximation: A Gradient Boosting Machine. Ann. Stat. 29(5).

[6] Guyon & Elisseeff (2003). An Introduction to Variable and Feature Selection. JMLR 3.

[7] Pedregosa et al. (2011). Scikit-learn: Machine Learning in Python. JMLR 12.

[8] Kaggle. House Prices: Advanced Regression Techniques. kaggle.com/c/house-prices-advanced-regression-techniques

CẢM ƠN THẦY VÀ CÁC BẠN ĐÃ LẮNG NGHE!

Q & A

nhóm 5 – Học Máy – Khoa CNTT – ĐH Sài Gòn