TRƯỜNG ĐẠI HỌC SÀI GÒN · KHOA CÔNG NGHỆ THÔNG TIN · MÔN HỌC MÁY

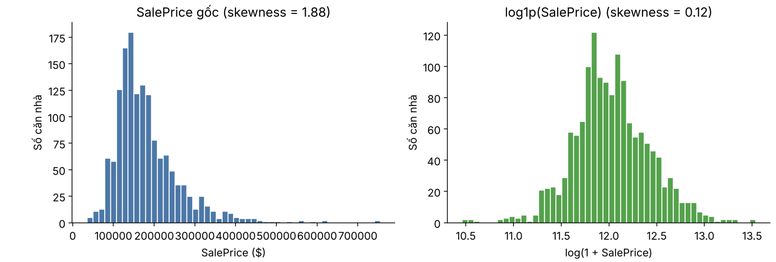
DỰ ĐOÁN GIÁ NHÀ: LỰA CHỌN ĐẶC TRƯNG, FEATURE ENGINEERING VÀ BLENDING TRÊN AMES HOUSING

Phạm Minh Khôi · Trương Thuận Phú · Nguyễn Mạnh Thắng · Nguyễn Hoàng Quân (nhóm 5 – Lớp DCT124C1)
Giảng viên hướng dẫn: TS. Đỗ Như Tài | Challenge 1: House Prices – Kaggle

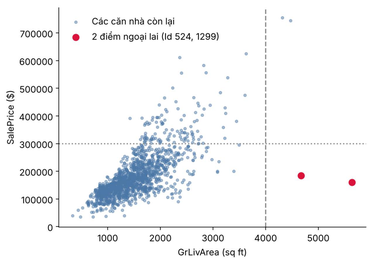
1. Bài toán & dữ liệu

- **Input:** 79 đặc trưng của căn nhà (diện tích, chất lượng, vị trí, năm xây, gara, tầng hầm…)
- **Output:** SalePrice (USD); mô hình hóa trên log1p(SalePrice)
- **Dữ liệu:** Ames Housing (Iowa, 2006–2010): 1.460 mẫu huấn luyện, 1.459 kiểm thử; 36 biến số + 43 biến định tính
- **Thách thức:** số chiều lớn, khuyết có ngữ nghĩa (PoolQC 99,5%), đa cộng tuyến, giá lệch phải
- **Thước đo:** RMSE và R^2 trên log1p, 5-fold CV không rò rỉ

2. Khám phá dữ liệu



Skewness giá: **1,88** → **0,12** sau log1p



- Loại **2 ngoại lai** (Id 524, 1299): > 4.000 sq ft nhưng giá thấp; cả hai là giao dịch **Partial**
- Theo khuyến nghị De Cock (2011)

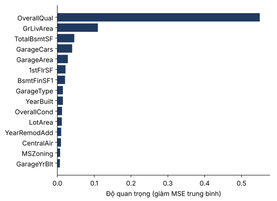
3. Phương pháp

1. Dữ liệu thô	2. Tiền xử lý	3. Chọn đặc trưng
1.460 nhà · 79 biến	Loại ngoại lai · điền khuyết · log1p	Full · KBest 30 · RF top-25
4. Mô hình hóa	**5. Đánh giá**	**6. Mô hình nộp**
Ridge · SVR · RF · GBDT · XGBoost	5-fold CV (Pipeline)	FE + blend → submission.csv

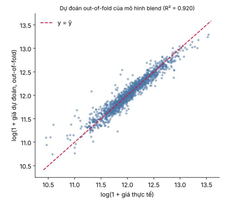
- **Tiền xử lý:** điền khuyết có ngữ nghĩa, loại ngoại lai, mã hóa nhãn, StandardScaler **trong Pipeline**
- **3 tập đặc trưng:** Full 79 · SelectKBest k = 30 · RF-importance top-25 (giảm 68,4% số biến)
- **5 mô hình:** Ridge, SVR, Random Forest, Gradient Boosting, XGBoost
- **Đánh giá:** 5-fold CV, chọn đặc trưng chạy riêng từng fold

4. Feature engineering + blending

- +8 đặc trưng mới (TotalSF, TotalBath, HouseAge, QualxArea…) → 87 biến; log1p 21 biến lệch
- Ridge (α = 100) + Lasso (α = 0,002) + GBDT (600 cây)
- **Blend:** 0,25 Ridge + 0,25 Lasso + 0,50 GBDT
- Dự đoán được chặn trong khoảng giá đã thấy ở train



Top 15 đặc trưng (Random Forest)



Out-of-fold, R^2 = 0,920

5. Kết quả chính (RMSE, 5-fold CV)

Mô hình	Full (79)	KBest (30)	RF top-25
Ridge	0,1218	0,1354	0,1287
SVR	0,1703	0,1559	0,1467
Random Forest	0,1390	0,1461	0,1385
Gradient Boosting	0,1269	0,1404	0,1269
XGBoost	0,1255	0,1401	0,1255

- **Ridge trên 79 biến tốt nhất** (0,1218; R^2 0,9065), ngang Gradient Boosting (0,1269)
- Chọn đặc trưng **không giúp** Ridge/cây; **giúp SVR −13,9%**

6. Ablation

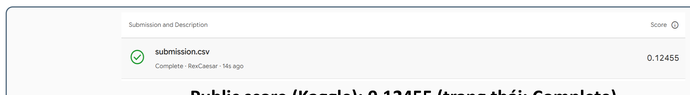
Ngoại lai	Biến mục tiêu	Ridge	GBDT
Đã loại	log1p	0,1221	0,1272
Đã loại	không log	0,1574	0,1298
Giữ lại	log1p	0,1388	0,1272
Giữ lại	không log	0,3520	0,1312

- Log: Ridge −22%; loại ngoại lai: Ridge −12%; mô hình cây gần như không đổi

7. Kết quả cuối & Kaggle

Blend: RMSE 0,1127 · R^2 0,9202 (baseline Ridge 0,1218)

- **Kết luận:** Ridge ≈ GBDT trên 79 biến; log và loại ngoại lai then chốt cho mô hình tuyến tính; blend giảm RMSE 7,5%.
- **Hạn chế:** α chọn trên cùng fold CV (chưa nested CV) nên CV hơi lạc quan; siêu tham số mô hình chính chưa tối ưu.



Public score (Kaggle): 0,12455 (trạng thái: Complete)
Cao hơn CV khoảng 0,012 (tập test là dữ liệu mới)

Tài liệu: De Cock (2011) J. Stat. Educ. 19(3) · Hoerl & Kennard (1970) · Tibshirani (1996) · Breiman (2001) · Friedman (2001) · Guyon & Elisseeff (2003) · Pedregosa et al. (2011) · Dữ liệu: kaggle.com/c/house-prices-advanced-regression-techniques