TRƯỜNG ĐẠI HỌC SÀI GÒN · KHOA CÔNG NGHỆ THÔNG TIN · MÔN HỌC MÁY

CHALLENGE 2: MUSIC GENRE CLASSIFICATION

Đặc trưng âm thanh, thông tin nghệ sĩ và các đặc điểm thu thập dữ liệu trong cuộc thi Kaggle SHAI

Nhóm 5 – Lớp DCT124C1

Phạm Minh Khôi (3124411135) · Trương Thuận Phú (3124411234) · Nguyễn Mạnh Thắng (3124411283) · Nguyễn Hoàng Quân (3124411250)

Giảng viên hướng dẫn: TS. Đỗ Như Tài

Tháng 11/2026

Nội dung trình bày

1. **Giới thiệu bài toán**
   Input/Output, dữ liệu, thước đo
2. **Khám phá dữ liệu (EDA)**
   Mất cân bằng lớp, đơn vị duration, dữ liệu thiếu, nghệ sĩ
3. **Phương pháp**
   3 tập đặc trưng, mã hóa nghệ sĩ out-of-fold, 7 mô hình
4. **Thực nghiệm**
   So sánh, ablation, ensemble, phân tích lỗi, nghệ sĩ chưa thấy, Kaggle
5. **Kết luận**
   Phát hiện chính, hạn chế, hướng phát triển

1. Phát biểu bài toán: phân loại thể loại bài hát

INPUT

14 đặc trưng âm thanh/số
(danceability, energy, loudness, acousticness, duration…)
+ tên nghệ sĩ

→

MÔ HÌNH

Phân loại đa lớp
Cây · SVM · LR · MLP
+ soft voting

→

OUTPUT

Class ∈ {0, 1, …, 10}
(11 thể loại, nhãn ẩn danh)

Dữ liệu

- 14.396 bài huấn luyện, 3.600 bài kiểm thử
- Lớp lệch: lớp 10 chiếm 27,5%, lớp 3 chỉ 2,2%
- Baseline đoán lớp đa số: 27,5% Accuracy

Thước đo

- Báo cáo **Accuracy** và **Macro-F1**
- Thước đo leaderboard: chưa xác nhận trên trang cuộc thi (điểm Kaggle: slide 19)
- 5-fold CV phân tầng, Pipeline (không rò rỉ)

Nguồn: Kaggle "SHAI Music Genre Classification".

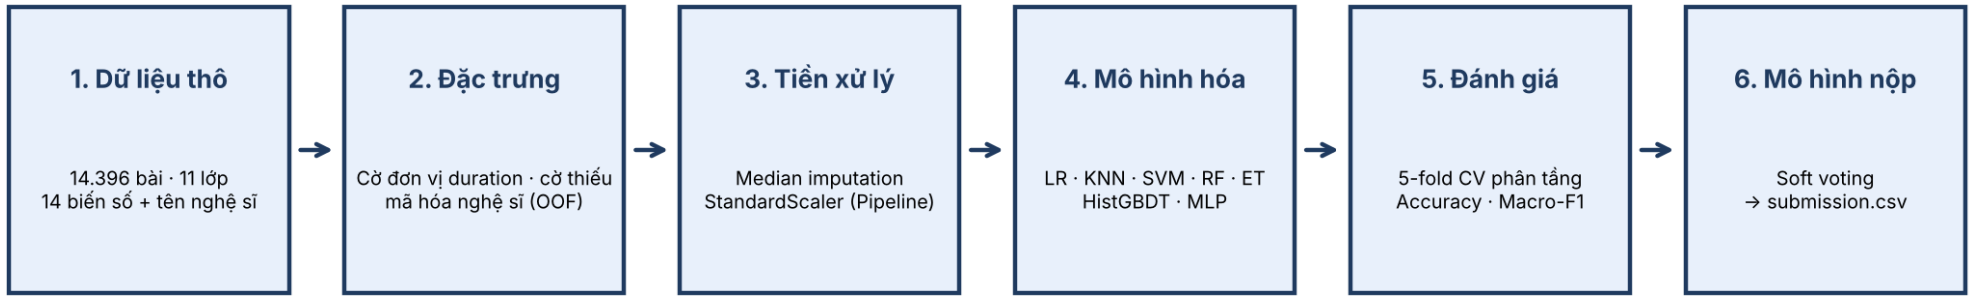
2. Bộ dữ liệu và những điểm cần lưu ý

Thuộc tính	Giá trị
Train / Test	14.396 / 3.600
Số lớp	11
Nghệ sĩ (train)	7.913
Thiếu: Popularity / key / instr.	2,3% / 11,2% / 24,6%

Điều đáng chú ý

- **Duration trộn đơn vị:** 14,4% bài ghi theo phút, gần như quyết định nhãn lớp 0, 3, 4, 7
- **Thiếu không ngẫu nhiên:** instrumentalness thiếu 0,2% (lớp 7) đến 61,4% (lớp 5)
- **Nghệ sĩ:** 63,8% mẫu test thuộc nghệ sĩ đã thấy ở train
- Các lớp chồng lấn về âm thanh

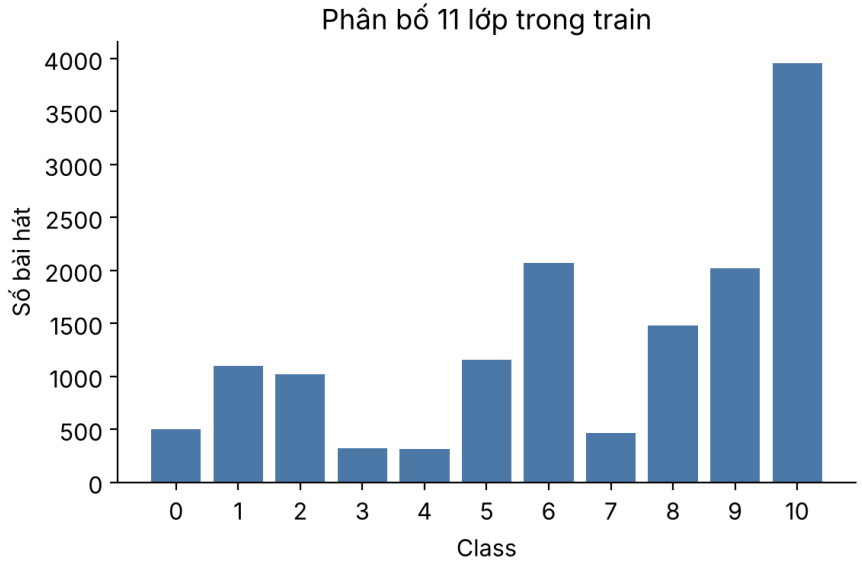
3. Quy trình thực nghiệm đầu–cuối

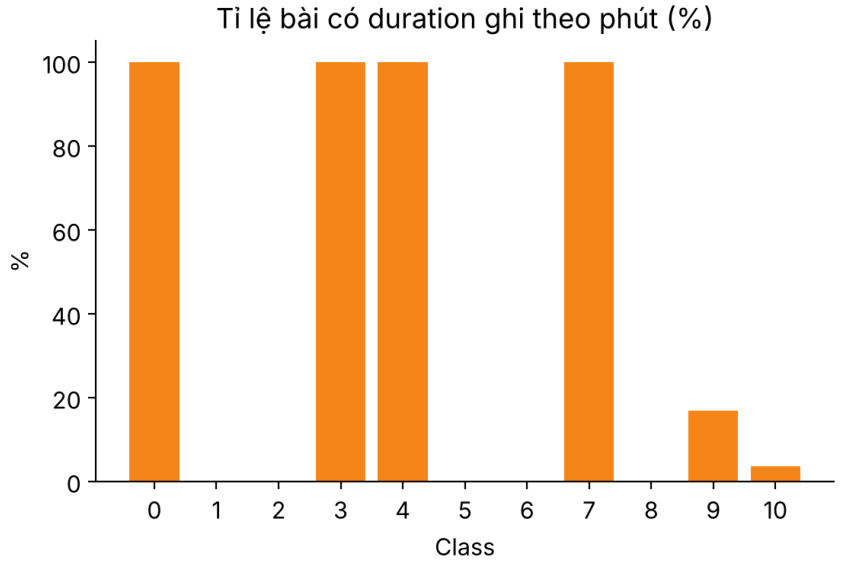


Điểm nhấn của quy trình

- Điền khuyết, chuẩn hóa và mã hóa nghệ sĩ nằm **trong Pipeline** → mỗi fold chỉ học từ train của fold
- Mã hóa nghệ sĩ dùng thống kê **out-of-fold** bên trong, tránh lộ nhãn của chính mẫu
- Đo riêng hiệu năng khi nghệ sĩ **chưa từng thấy** (artist filter)

EDA: mất cân bằng lớp và đơn vị của duration

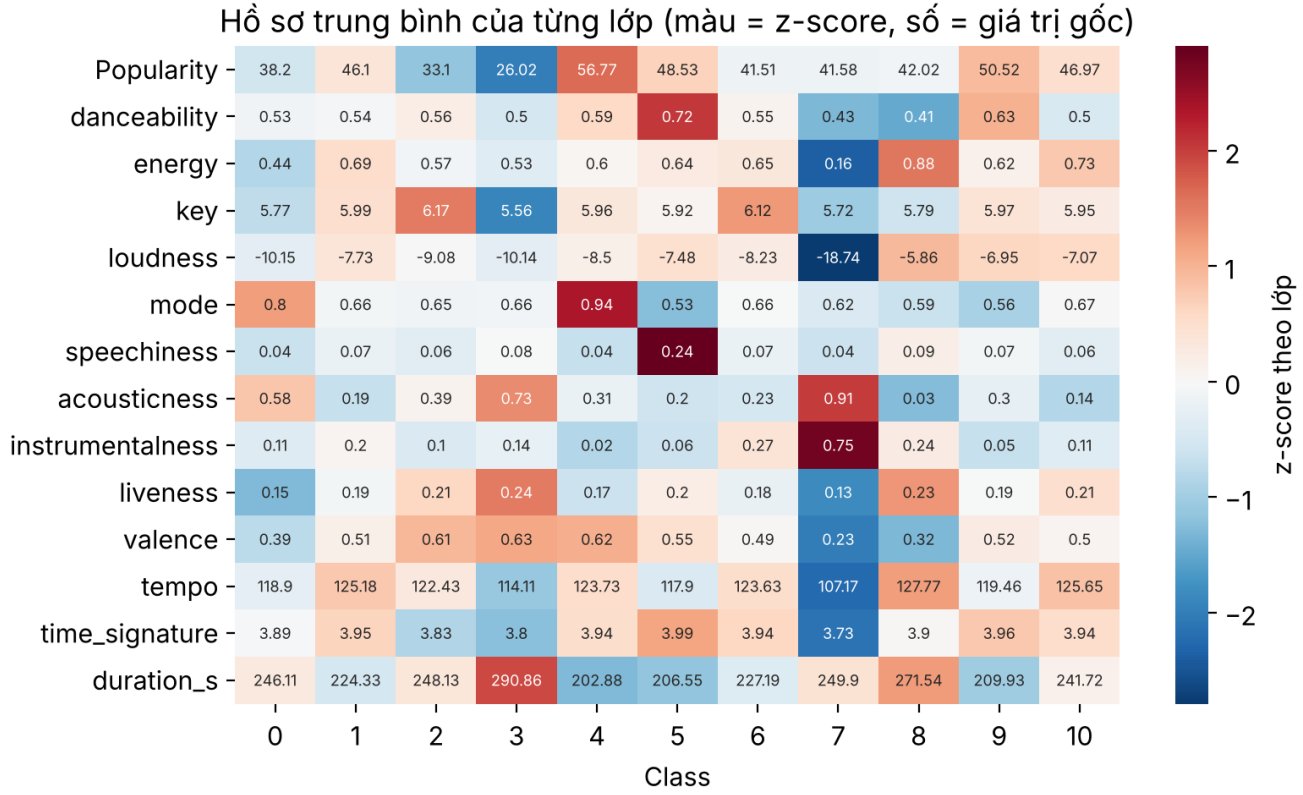




Nhận xét

- Lớp 10: 3.959 bài (27,5%); lớp 3: 322 bài (2,2%) → cần Macro-F1 và phân tích theo lớp
- Lớp 0, 3, 4, 7 ghi duration **100% theo phút**; lớp 1, 2, 5, 6, 8 gần như 0%

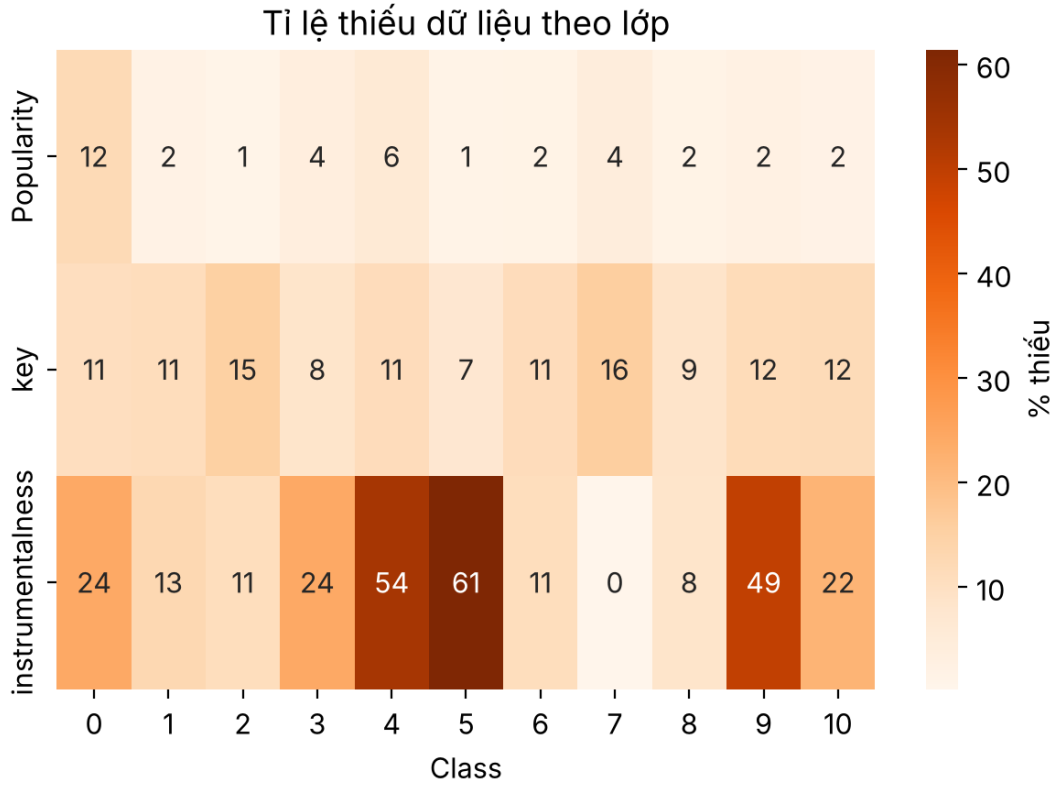
EDA: hồ sơ âm thanh của từng lớp



Nhận xét

- **Lớp 7:** energy 0,16, loudness −18,7 dB, acousticness 0,91
- **Lớp 5:** speechiness 0,24, danceability 0,72
- **Lớp 8:** energy 0,88, acousticness 0,03
- **Lớp 3:** Popularity thấp (26)
- Phần lớn các lớp còn lại có hồ sơ gần nhau

EDA: dữ liệu thiếu mang thông tin về nhãn



Hệ quả

- Instrumentalness thiếu từ 0,2% (lớp 7) đến 61,4% (lớp 5)
- Việc "thiếu" là tín hiệu → giữ mẫu, điền median và **thêm cờ thiếu**
- Cây quyết định xử lý tốt nhưng mô hình tuyến tính cần cờ tường minh
- Đây là đặc điểm thu thập, không phải tính chất âm nhạc

4. Ba tập đặc trưng

A – Thô

- 14 đặc trưng số
- Thiếu → median

B – A + kỹ thuật

- Cờ đơn vị duration
- duration quy về ms
- 3 cờ thiếu dữ liệu

C – B + nghệ sĩ

- Tần suất nghệ sĩ (không dùng nhãn)
- 11 biến mã hóa theo nhãn, out-of-fold

Mọi tập đều đi qua cùng Pipeline: median → StandardScaler → mô hình.

Mã hóa nghệ sĩ theo nhãn (target encoding), out-of-fold

$$TE_k(a) = (n_{a,k} + m \cdot p_k) / (n_a + m), \quad m = 5$$

Ý tưởng

- $n_{a,k}$: số bài của nghệ sĩ a thuộc lớp k
- p_k: tần suất lớp k (làm mượt)
- Nghệ sĩ chưa thấy → trả về p_k

Tránh rò rỉ

- Hàng train: thống kê từ vòng 5-fold **bên trong** tập train
- Validation/test: thống kê từ cả tập train của fold
- Nằm trong Pipeline → CV không lộ nhãn

Micci-Barreca (2001), SIGKDD Explorations 3(1).

5. Bảy mô hình được so sánh

Logistic Regression	Đa lớp, chuẩn hóa
KNN	k = 15
SVM (RBF)	C = 1
Random Forest · Extra Trees	300 cây mỗi mô hình
HistGBDT	200 vòng, lr = 0,08
MLP	128–64, early stopping

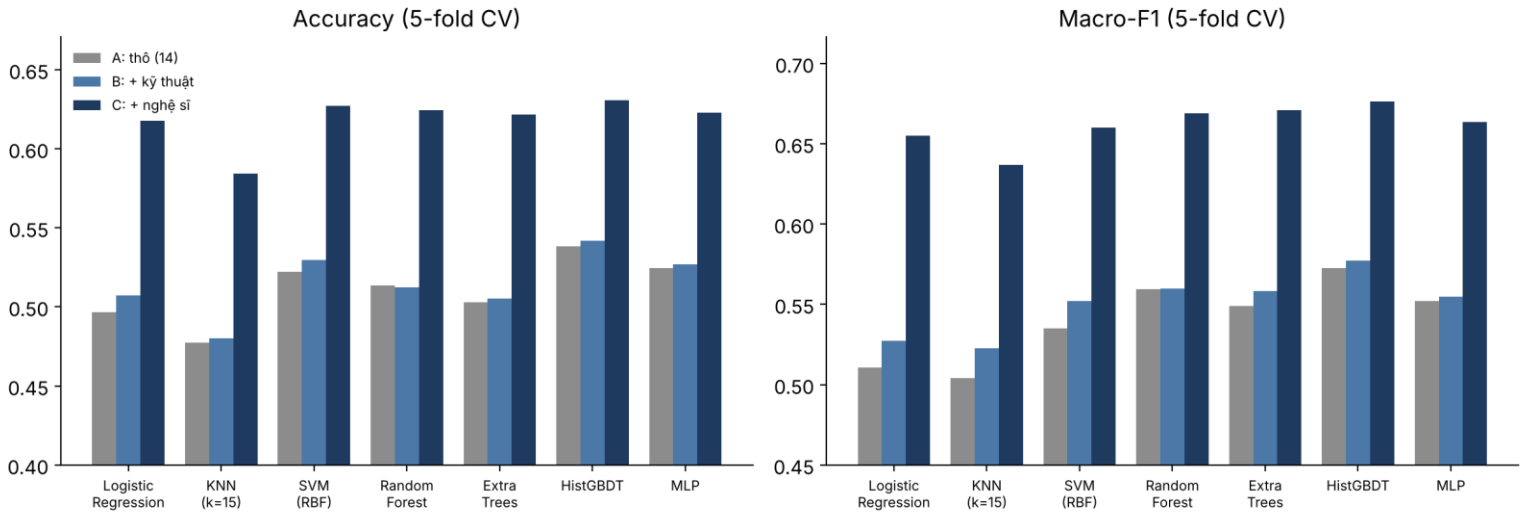
Siêu tham số mặc định hợp lý ở bước so sánh; HistGBDT được tinh chỉnh bằng random search (10 cấu hình).

6. Kết quả chính: Accuracy theo mô hình và tập đặc trưng

Mô hình	A: thô	B: + kỹ thuật	C: + nghệ sĩ
Logistic Regression	0,4966	0,5072	0,6175
KNN (k=15)	0,4775	0,4800	0,5844
SVM (RBF)	0,5223	0,5297	0,6273
Random Forest	0,5134	0,5125	0,6245
Extra Trees	0,5029	0,5052	0,6215
HistGBDT	0,5383	0,5417	0,6307
MLP	0,5247	0,5271	0,6227

Chỉ dùng âm thanh: tối đa 0,5383 (HistGBDT). Thêm nghệ sĩ: 0,6307 (+9,2 điểm so với chỉ âm thanh; +8,9 điểm so với tập B).

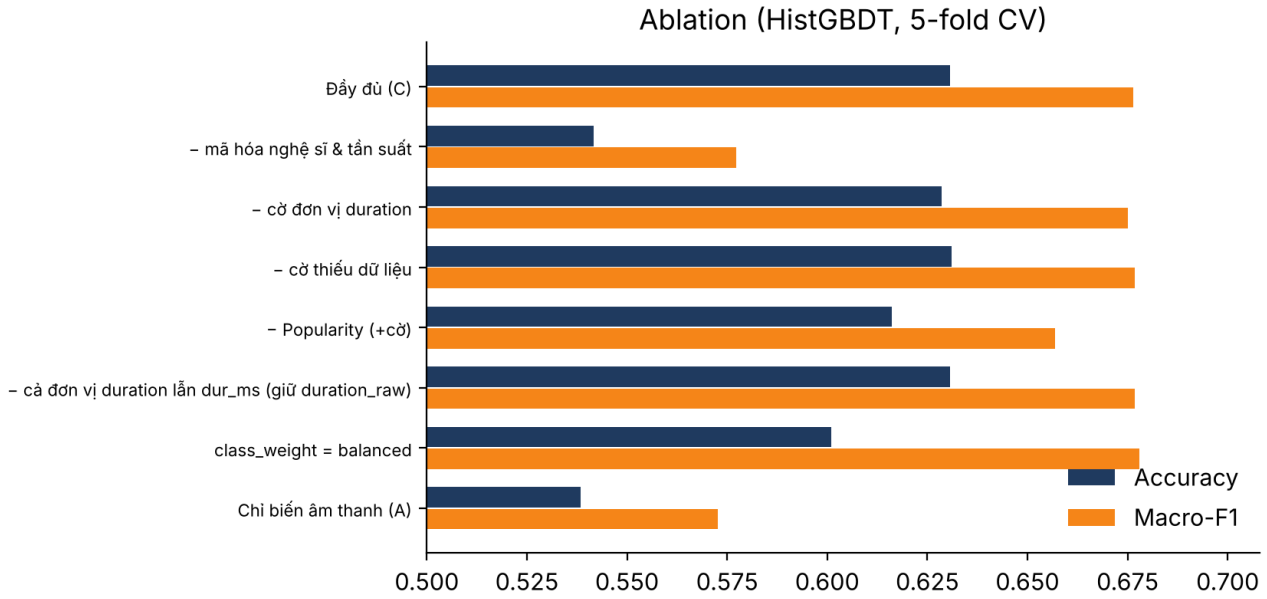
Tác động của đặc trưng lớn hơn tác động của mô hình



Kết luận từ số liệu

- Âm thanh thuần: các mô hình chỉ cách nhau ~6 điểm
- Cờ kỹ thuật (B): tăng nhẹ, chủ yếu với mô hình tuyến tính
- Nghệ sĩ (C): tăng 9–12 điểm cho **mọi** mô hình

7. Ablation trên HistGBDT



Đọc kết quả

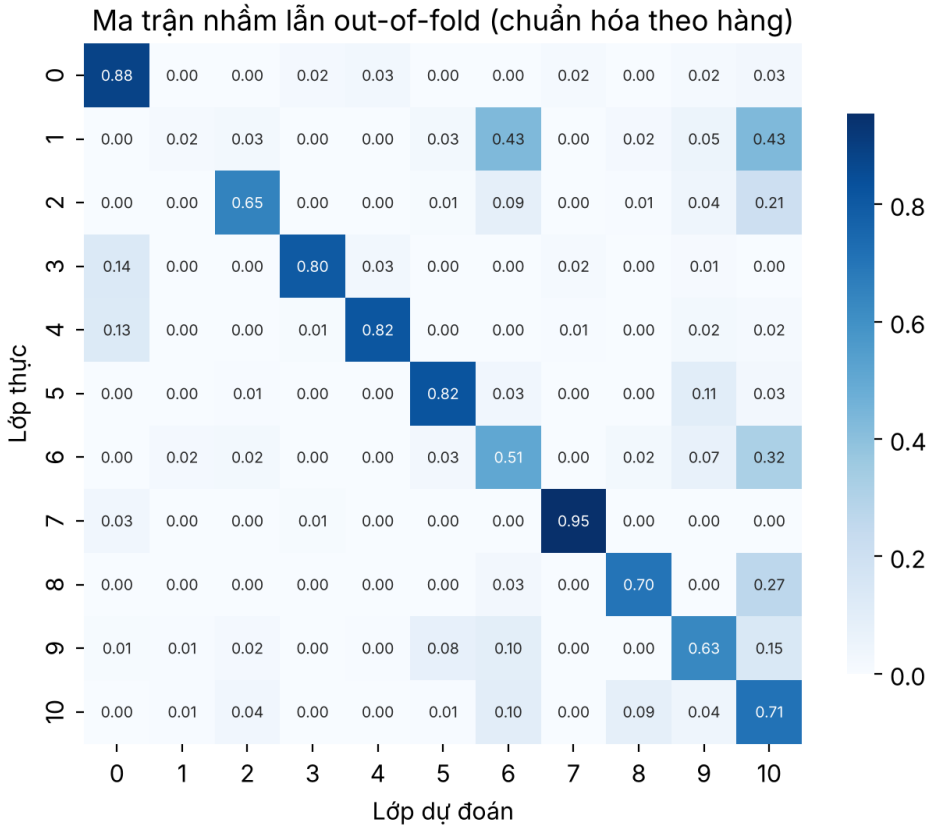
- Bỏ nghệ sĩ: −8,9 điểm
- Bỏ Popularity: −1,5 điểm
- Bỏ cờ đơn vị / cờ thiếu: < 0,3 điểm (cây đã có duration_raw và NaN)
- class_weight = balanced: Accuracy 0,601, Macro-F1 không đổi

8. Tinh chỉnh và kết hợp mô hình (soft voting)

Cấu hình	Accuracy	Macro-F1
HistGBDT (tuned)	0,6355	0,6784
HGB + ET	0,6384	0,6810
HGB + RF + ET	0,6355	0,6781
HGB + RF + ET + LR	**0,6403**	**0,6783**
HGB + RF + ET + LR + MLP	0,6368	0,6762

- Chọn: **HGB + RF + ET + LR** → Accuracy **0,6403 ± 0,0045**, Macro-F1 **0,6783**
- Chênh lệch giữa các tổ hợp < độ lệch chuẩn giữa fold, và tổ hợp cùng siêu tham số được chọn trên chính 5 fold này → có thể hơi lạc quan

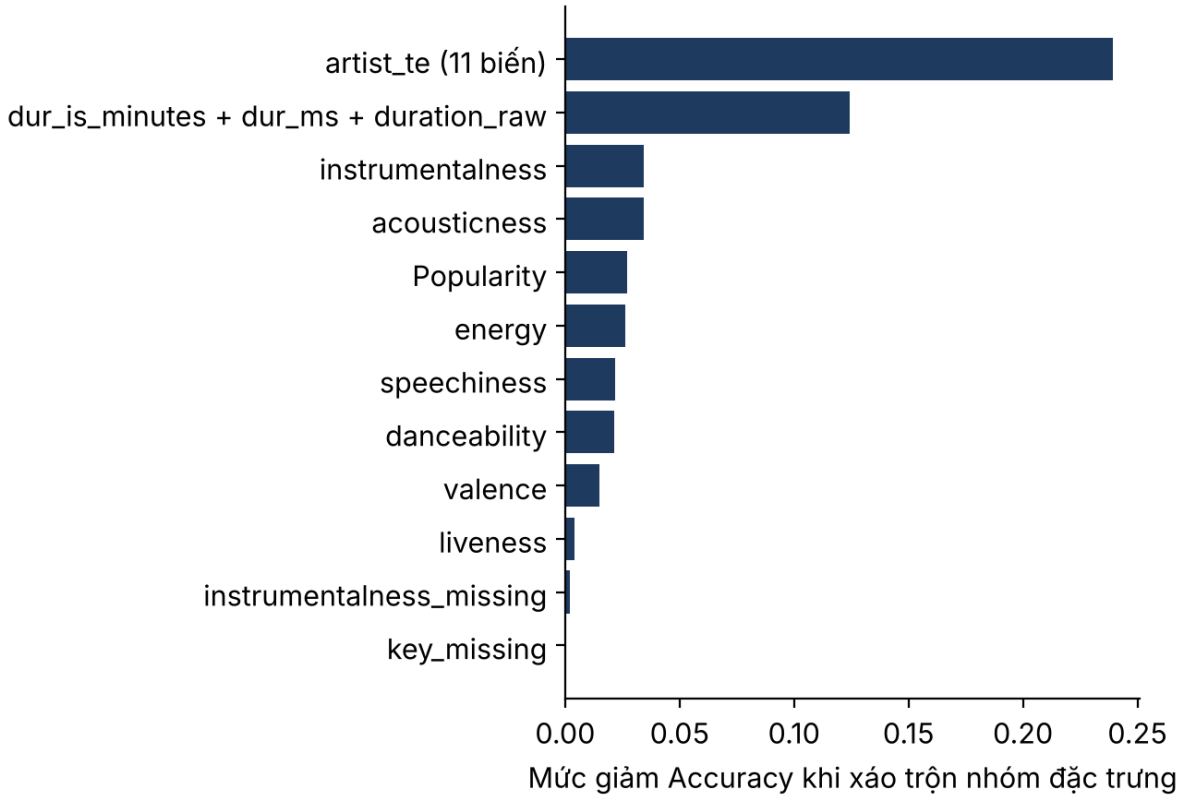
9. Phân tích lỗi theo lớp



Nhận xét

- Tốt: lớp 7 (F1 0,96), lớp 3 (0,85), lớp 4 (0,83), lớp 0 (0,83)
- **Lớp 1 gần như không nhận diện được** (F1 0,03): 43% → lớp 10, 43% → lớp 6
- Lớp 6, 8, 2 hay bị nhầm về lớp 10 (lớp đa số)
- Mô hình dự đoán lớp 10 cho 34% mẫu test (thật ~27,5%)

Mô hình dựa vào đâu để quyết định?



Độ quan trọng (hoán vị nhóm, fold 1, HistGBDT đã tinh chỉnh)

- Mã hóa nghệ sĩ: −23,9 điểm Accuracy
- Nhóm duration: −12,4 điểm
- Âm thanh (instrumentalness, acousticness…): ~3 điểm mỗi biến
- Phần lớn độ chính xác đến từ nghệ sĩ và đặc điểm thu thập, không phải âm thanh thuần

10. Khi nghệ sĩ chưa từng xuất hiện trong train

Điều kiện	Accuracy
CV thường – nghệ sĩ đã thấy	0,6747
CV thường – nghệ sĩ chưa thấy	0,5915
Chia theo nghệ sĩ, không dùng nghệ sĩ	0,5447
Chia theo nghệ sĩ, có mã hóa nghệ sĩ	0,5242

- CV thường có 58,7% mẫu thuộc nghệ sĩ đã thấy, gần 63,8% ở test thật → ước lượng hợp lý cho leaderboard
- Với nghệ sĩ mới, mã hóa nghệ sĩ không còn giúp ích (thậm chí kém hơn) → hiệu năng chỉ ~0,55

Flexer (2007), ISMIR: artist filter cho phân loại thể loại.

11. Kết quả nộp bài trên Kaggle



File nộp: **submission.csv** | Public score: 0,65753 | Private score: 0,64166 | nộp sau hạn chót

12. Kết luận và hướng phát triển

Kết luận

- Chỉ âm thanh: 0,538; thêm nghệ sĩ: 0,631; mô hình nộp: 0,640 (Macro-F1 0,678); Kaggle Private 0,642
- Chênh lệch giữa các mô hình nhỏ so với tác động của đặc trưng
- Lợi ích của nghệ sĩ phụ thuộc việc nghệ sĩ đã thấy ở train
- Duration lẫn đơn vị và dữ liệu thiếu là "đường tắt" của bộ dữ liệu

Hạn chế và hướng tiếp theo

- Thước đo leaderboard chưa xác nhận
- Ensemble và siêu tham số chọn trên cùng 5 fold; chưa nested CV
- Lớp 1 gần như không nhận diện được
- Tối ưu ngưỡng theo lớp cho Macro-F1, CatBoost/LightGBM, đặc trưng từ tên bài, artist filter chuẩn

Tài liệu tham khảo

[1] Tzanetakis & Cook (2002). Musical genre classification of audio signals. IEEE Trans. Speech Audio Process. 10(5).

[2] Flexer (2007). A closer look on artist filters for musical genre classification. ISMIR 2007.

[3] Micci-Barreca (2001). A preprocessing scheme for high-cardinality categorical attributes… SIGKDD Explorations 3(1).

[4] Breiman (2001). Random Forests. Machine Learning 45(1).

[5] Geurts et al. (2006). Extremely randomized trees. Machine Learning 63(1).

[6] Friedman (2001). Greedy Function Approximation: A Gradient Boosting Machine. Ann. Stat. 29(5).

[7] He & Garcia (2009). Learning from imbalanced data. IEEE TKDE 21(9).

[8] Pedregosa et al. (2011). Scikit-learn: Machine Learning in Python. JMLR 12.

[9] Kaggle. SHAI Music Genre Classification. kaggle.com/competitions/shai-music-genre-classification

CẢM ƠN THẦY VÀ CÁC BẠN ĐÃ LẮNG NGHE!

Q & A

Nhóm 5 – Học Máy – Khoa CNTT – ĐH Sài Gòn